

BẢN TỔNG HỢP LÝ THUYẾT CHI TIẾT: K-NEAREST NEIGHBORS (KNN)

1 Định nghĩa & Bản chất

KNN là thuật toán học có giám sát thuộc nhóm **Non-parametric** (không giả định phân phối dữ liệu) và **Lazy Learning** (không có quá trình "học/huấn luyện" mô hình trước; toàn bộ tính toán được hoãn lại đến khi cần dự đoán).

KNN dự đoán giá trị của điểm dữ liệu mới dựa trên **sự tương đồng (khoảng cách)** đối với K điểm dữ liệu gần nó nhất trong tập train.

2 Các công thức & Hàm toán học

- Đo khoảng cách (Distance Metrics):

- Euclidean Distance (L2 norm - Phổ biến nhất):

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

- Manhattan Distance (L1 norm):

$$d(p, q) = \sum_{i=1}^n |p_i - q_i|$$

- Minkowski Distance (Tổng quát):

$$d(p, q) = \left(\sum_{i=1}^n |p_i - q_i|^p \right)^{\frac{1}{p}}$$

- Cơ chế dự đoán:

- Bài toán Phân loại (Classification): Bỏ phiếu theo đa số (Majority Voting) trong K hàng xóm.
- Bài toán Hồi quy (Regression): Tính giá trị trung bình cộng (hoặc trung bình có trọng số) của K hàng xóm:

$$\hat{y} = \frac{1}{K} \sum_{i \in \text{Neighbors}} y_i$$

3 Cách áp dụng quy chuẩn trong Python

```
1 from sklearn.neighbors import KNeighborsRegressor # Hoac
   KNeighborsClassifier
2 from sklearn.preprocessing import StandardScaler
3
4 # BAT BUOC: Chuan hoa du lieu truoc khi dung KNN
5 scaler = StandardScaler()
6 X_train_scaled = scaler.fit_transform(X_train)
7 X_test_scaled = scaler.transform(X_test)
8
9 # Khoi tao va du doan
10 knn = KNeighborsRegressor(n_neighbors=5)
11 knn.fit(X_train_scaled, y_train)
12 y_pred = knn.predict(X_test_scaled)
```

4 Khi nào nên dùng?

- Tập dữ liệu nhỏ hoặc trung bình.
- Cần một mô hình đơn giản, không cần đưa ra giả định về phân phối hình học của dữ liệu.
- Phù hợp cho các hệ thống gợi ý đơn giản (Recommendation System dựa trên người dùng tương đồng).

5 Ý nghĩa & Giá trị thực tế

- Thể hiện tư duy tự nhiên: *"Những đối tượng giống nhau thì thường có thuộc tính/hành vi giống nhau"*.
- Cực kỳ linh hoạt vì có thể áp dụng cho cả bài toán Phân loại lẫn Hồi quy.

6 Không ổn với loại dữ liệu nào?

- **Dữ liệu chưa chuẩn hóa quy mô (Unscaled Data):** Thuộc tính có khoảng giá trị lớn sẽ áp đảo hoàn toàn các thuộc tính khác khi tính khoảng cách Euclidean.
- **Dữ liệu số chiều cao (High-dimensional Data / Curse of Dimensionality):** Khi số lượng cột X quá nhiều, khoảng cách giữa các điểm rơi vào tình trạng "mất ý nghĩa" (điểm nào cũng xa nhau như nhau).
- **Tập dữ liệu cực lớn (Large Scale Data):** Khi dự đoán 1 mẫu mới, KNN phải tính khoảng cách tới **toàn bộ** các mẫu trong tập Train → Tốn bộ nhớ RAM và thời gian dự đoán siêu chậm.
- **Dữ liệu có nhiều Outlier hoặc Nhiễu:** Điểm nhiễu có thể làm sai lệch hoàn toàn kết quả lấy trung bình của K hàng xóm xung quanh.