

BẢN TỔNG HỢP LÝ THUYẾT CHI TIẾT: RANDOM FOREST (RỪNG NGẪU NHIÊN)

1 Định nghĩa & Bản chất

Random Forest là thuật toán học tập hợp (Ensemble Learning) kết hợp nhiều Cây quyết định (Decision Trees) độc lập. Thuật toán sử dụng kỹ thuật **Bagging** (Bootstrap Aggregating) kết hợp với **Random Subspace Method** để giảm hiện tượng Overfitting và nâng cao độ ổn định của dự đoán.

2 Các cơ chế & Công thức vận hành

- **Bootstrap Sampling:** Tạo N mẫu dữ liệu mới từ tập train bằng cách lấy mẫu có hoàn lại (Random sampling with replacement).
- **Random Feature Selection:** Tại mỗi nút chia của mỗi cây, chỉ chọn ngẫu nhiên $k = \sqrt{D}$ thuộc tính (đối với Phân loại) hoặc $k = D/3$ thuộc tính (đối với Hồi quy) để tìm điểm chia tốt nhất.
- **Tổng hợp dự đoán (Aggregation):**

- **Phân loại:** Bỏ phiếu đa số (Majority Voting) từ tất cả các cây:

$$\hat{y} = \text{mode}(\hat{y}_1, \hat{y}_2, \dots, \hat{y}_T)$$

- **Hồi quy:** Lấy trung bình cộng dự đoán từ các cây:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T \hat{y}_t$$

3 Cách áp dụng quy chuẩn trong Python

```
1 from sklearn.ensemble import RandomForestClassifier # Hoac
   RandomForestRegressor
2
3 rf = RandomForestClassifier(n_estimators=100, max_depth=10,
   random_state=42, n_jobs=-1)
4 rf.fit(X_train, y_train)
```

```
5  
6 y_pred = rf.predict(X_test)  
7 importances = rf.feature_importances_
```

4 Khi nào nên dùng?

- Cần độ chính xác cao trên dữ liệu dạng bảng (Tabular Data).
- Khắc phục hoàn toàn điểm yếu Overfitting của một Cây quyết định đơn lẻ.
- Dữ liệu chứa Outlier hoặc có nhiều giá trị bị khuyết (Missing values).

5 Ý nghĩa & Giá trị thực tế

- Một trong những thuật toán mạnh mẽ và toàn diện nhất trong Machine Learning truyền thống.
- Cung cấp độ đo ‘feature importance’ trong mô hình.

6 Không ổn với loại dữ liệu nào?

- **Dữ liệu chuỗi thời gian (Time-series Data):** Kỹ thuật lấy mẫu ngẫu nhiên Bootstrap phá vỡ thứ tự thời gian tự nhiên của dữ liệu.
- **Dữ liệu cực kỳ thưa (Sparse High-dimensional Data như NLP / TF-IDF):** Khi chọn ngẫu nhiên ít thuộc tính tại mỗi nút, khả năng cao các thuộc tính chọn ra đều bằng 0.
- ****Yêu cầu dự đoán thời gian thực (Ultra Low-latency):**** Dự đoán qua hàng trăm cây tốn nhiều tài nguyên tính toán hơn so với Logistic hay Linear Regression.